Para esta tarea, cada integrante realizó su propio esquema relacional. La comparación que podemos realizar entre el diagrama realizado por nosotros y el entregado por LLM, es la siguiente:

Iñaki Guridi:

Por un lado, tuvimos la suerte de que descubrimos gracias a Chat GPT que en la página mermaid, las LLM son capaces de pasar código a imagen con el lenguaje *er Diagram*. Debido a esto se nos hizo más fácil visualizar el diagrama. Desde la primera instancia, lo realizó casi perfecto, considerando el siguiente prompt *"Haz el diagrama que se solicita que haga una LLM"*, y adjunté el pdf del enunciado. A lo que obtuve como salida la siguiente conversación con Chat GPT: https://chatgpt.com/share/69dea6d3-09d8-83e9-9763-972c3470fb13.
En el caso del diagrama que fue realizado por cada uno, notamos que no teníamos tantos detalles, tales como el tipo de key o el tipo de dato (int, str, etc…), mientras que el hecho por LLM si los tenía. Lo que sí hubo que corregir, fue la relación entre algunos esquemas, ya que hizo conecciones que si bien no estaban mal necesariamente, creemos que quedan mejor de la manera que lo re-formateamos. Además, creó tablas adicionales, unas que sí sirven, como la de auspicios que actúan de intermediarios entre sponsor (las marcas en sí) y torneo, y otras que tuvimos que eliminar, como una llamada "partida equipo", que relacionaba a los equipos con la partida.

Cristóbal Ross:

Al comparar mi esquema con el del LLM, me di cuenta de que una diferencia importante estuvo en los tipos de datos, porque como estoy acostumbrado a Python pensaba en cosas como string en vez de tipos propios de SQL como varchar. De todas formas, lo que más me costó no fueron los tipos, sino modelar bien las relaciones para capturar las restricciones del problema. Ahí el LLM sí me ayudó, porque me orientó mejor en cómo representar ciertas reglas mediante llaves foráneas y relaciones entre tablas.

Los errores que note fueron que, en algunos casos creó tablas extra que no eran necesarias, y en otros propuso relaciones redundantes que ya estaban implícitas en las llaves del esquema. Eso hace que el diseño sea menos limpio y más difícil de justificar. Por lo tanto, considero que el LLM fue útil como apoyo, pero no suficiente por sí solo, ya que su esquema igual necesitó correcciones para ajustarse mejor a los requerimientos y a un diseño relacional más adecuado.

Gonzalo Molina:

Al comparar mi esquema con el generado por el LLM, noté diferencias importantes en el enfoque. Mi diseño estaba más centrado en identificar las entidades y sus relaciones, mientras que el del LLM estaba más orientado a la implementación, considerando atributos, tipos de datos, claves primarias y foráneas, e incluso algunas restricciones adicionales.

Una gran mejora del LLM fue incluir correctamente relaciones muchos-a-muchos mediante tablas intermedias como SPONSOR_TORNEO. También el LLM intentó incorporar varias restricciones del problema, como por ejemplo: que el capitán pertenezca al equipo, que un jugador no cambie de equipo y que no se exceda el cupo máximo del torneo.

Finalmente, al comparar distintas respuestas de IA y descubrí que a Iñaki le dió su respuesta usando erDiagram, y al decirle que incorpore mi diagrama y que use esta sintaxis, logré combinar lo mejor de ambos, la estructura de mi diseño inicial con el detalle del LLM. El LLM fue de gran ayuda, sin embargo, quedó claro que la etapa de diseño manual y comparación fue clave para corregir errores de ambas partes.

El prompt usado fue el siguiente (junto con los archivos necesarios): “Necesito que hagas la parte A de la tarea. Debe ser lo más completa posible, incluyendo atributos, entidades y relaciones necesarias. Usa como guía las presentaciones de las clases y la imagen de ejemplo”. La respuesta es posible verla en el siguiente link: https://chatgpt.com/share/69dea602-ae00-83e9-af5e-cc453b022cf9

Conclusión:
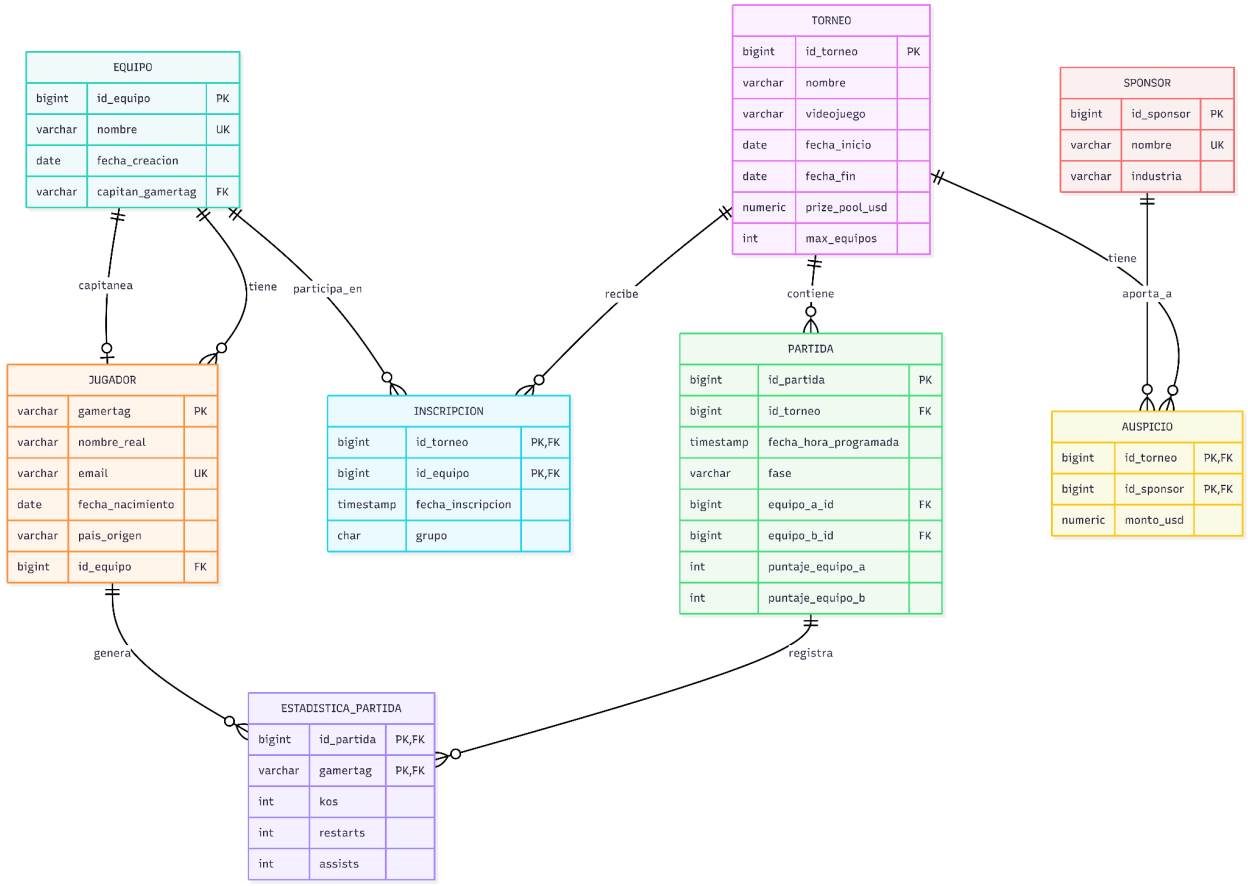
Juntando las respuestas de los tres LLM y correcciones nuestras, llegamos al siguiente esquema: